

Renato Gates

Segunda tarea

“IA Generativa Aplicada a las Ciencias Sociales y la Gestión Pública”


1 Consulta RUC

La base de datos a scrapear es la de consulta tu ruc (SUNAT), esta muestra, en base a algun documento de identificación como DNI o RUC; el estado de actividad de dicho documento. De esta forma es una buena idea de interés verificar si es que tenemos una lista de empresas o personas naturales, junto a un grupo de dni's o rucs, para verificar si se encuentra operando en base a lo suscrito por SUNAT. Esto puede ser muy útil si es que se busca realizar algun tipo de verificación con las empresas, sobre todo si es que es a gran escala de empresas. Para fines de investigación o simplemente validar una lista de proveedores o contrapartes. El código permite automatizar este proceso para cualquier número de empresas, extrayendo el estado y condición del contribuyente de forma sistemática. La página a utilizar sera: Sunat CONSULTA tu RUC: <https://e-consultaruc.sunat.gob.pe/>

2 Tipo de fuente



La página de CONSULTA RUC, nos muestra para acceder a través del RUC de la empresa o persona naturla.



Al presionar Control + U, podemos notar que el código fuente de la página está escrito en HTML. Por ese motivo, es posible identificar los elementos de la interfaz: como el campo de ingreso del RUC y el botón de búsqueda. De esta forma, podemos ver que el mejor método para scrapear es utilizando selenium.

3 Proceso de scrapeo

El proceso de scraping se realizó siguiendo los pasos detallados a continuación:

- **Instalación del entorno:** Se instalaron las librerías necesarias (**selenium**, **webdriver-manager**) y Chrome en el entorno de Google Colab.
- **Configuración del WebDriver:** Se inicializó Chrome en modo headless con **ChromeDriverManager**.
- **Navegación a la página:** El driver abrió la URL del portal de Consulta RUC de SUNAT.
- **Ingreso del RUC:** Se escribió el RUC en el campo de texto y se hizo clic en el botón. De esta forma, con el tiempo de espera de 30 segundos, nos aseguramos que se obtenga la información correcta.
- **Extracción de datos:** Se ubicaron los elementos de estado y condición del contribuyente mediante rutas XPath y se extrajo su texto.
- **Iteración:** Los pasos anteriores se repitieron para cada RUC de la lista, inicializando un nuevo driver por cada empresa consultada.

- **Exportación:** Los resultados se consolidaron en un DataFrame y se exportaron a un archivo Excel con formato hacia Google Drive.